DeepSDF pour jumeau numérique d'aéroport et prédiction de dispersion de NOx

OpenALAQS · DeepSDF · Fourier Features · U-Net 3D · Visualisation volumique

Rapport

Projet : IA & Application

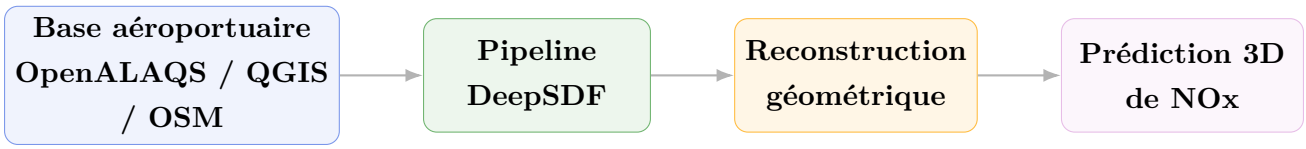
Rédigé par : Haroun Joudi

Enseignante : Souhaila Arib

Encadrant : Abdellahi Babah

Établissement : CY Tech

Période : Mars 2026 – Avril 2026



Ce rapport constitue une description technique détaillée du travail réalisé : contexte, processus, résultats, limites et perspectives.

Table des matières

Résumé **3**

1 Contexte, objectifs et logique générale du projet **5**
1.1 Problématique générale 5
1.2 Objectifs scientifiques et techniques 5
1.3 Lecture du projet retenue dans ce rapport 5

2 Première approche : reconstruction géométrique par OpenALAQS et DeepSDF **7**
2.1 Choix de la scène et préparation de la base aéroportuaire 7
2.2 Du polygone 2D à la géométrie 3D 8
2.3 Génération du dataset SDF 8
2.4 Architecture du modèle DeepSDF 9
2.5 Entraînement et suivi géométrique 10
2.6 Reconstruction finale et rendus 3D 12
2.7 Comparaison référence / prédiction en hauteur 13
2.8 Coupes SDF et lecture du champ appris 14
2.9 Évaluation finale et génération du masque d'obstacles 15
2.10 Pourquoi cette première approche n'a pas été retenue comme résultat principal 16

3 Seconde approche : prédiction volumique de dispersion de NOx **18**
3.1 Introduction 18
3.2 Caractéristiques de la base HDF5 18
3.3 La notion de scénario 19
3.4 Entrées, sortie et représentation volumique 19
3.5 Architecture du modèle final 20
3.6 Protocole d'entraînement et cadre expérimental 20
3.7 Stabilisation du notebook final 21

4 Résultats expérimentaux du système NOx **22**
4.1 Courbes d'apprentissage 22
4.2 Lecture des métriques globales 22
4.3 Matrice de confusion 23
4.4 Analyse qualitative sur des scénarios représentatifs 24
4.5 Meilleurs et pires cas 25
4.6 Lecture des scénarios les plus favorables 26
4.7 Visualisations 3D et vidéo 27
4.8 Bilan scientifique 27

5 Discussion générale, limites et perspectives d'adaptation **28**
5.1 Ce que le projet démontre 28
5.2 Limites identifiées 28
5.3 Perspectives d'amélioration côté DeepSDF 28
5.4 Perspectives d'amélioration côté NOx 29

6 Conclusion **30**

Résumé

Ce rapport présente le travail réalisé autour d'un sujet de jumeau numérique géométrique d'aéroport par apprentissage profond, puis sa réorientation vers un système de prédiction volumique de dispersion de NOx. Le projet a d'abord été abordé conformément à l'énoncé initial : construction d'une base géométrique aéroportuaire, génération d'un dataset de distance signée, entraînement d'un modèle de type DeepSDF, reconstruction 3D, visualisations et génération d'un masque d'obstacles. Cette première chaîne a bien été implémentée et exécutée jusqu'au bout sur Google Colab, avec un suivi géométrique explicite pendant l'entraînement.

Le run final retenu pour cette partie DeepSDF a été réalisé sur l'aéroport de Paris-Orly. Il s'appuie sur un maillage de référence de 11 252 sommets et 19 816 faces, un dataset SDF de 2,1 millions de points, et un MLP de 1,89 million de paramètres enrichi par Fourier Features. Les résultats montrent qu'une reconstruction géométrique cohérente peut être obtenue : les structures principales de la scène sont visibles, les vues orbitales et les coupes en hauteur restent lisibles, et le masque d'obstacles généré peut être évalué quantitativement. Néanmoins, malgré plusieurs optimisations de code et de protocole, la géométrie finale demeure incomplète. L'IoU d'occupation final atteint 0,375, avec une précision de 0,788 mais un rappel limité à 0,417. Ces résultats montrent un système fonctionnel, mais encore insuffisant pour en faire à lui seul la pièce maîtresse du rendu final.

Dans un second temps, le projet a donc été poursuivi à partir d'une base HDF5 fournie par monsieur Abdellahi Babah, contenant 3 000 scénarios 3D structurés de vent, géométrie, émissions et concentration cible de NOx. Cette base a permis de déplacer l'effort scientifique du problème de reconstruction géométrique vers celui, plus directement applicatif, de la prédiction volumique d'un panache de pollution. Un notebook dédié a été mis au point autour d'une architecture 3D U-Net de 22,58 millions de paramètres. Le protocole expérimental a été instrumenté de manière complète : séparation train/validation/test, sélection du meilleur checkpoint sur une métrique centrée sur le panache, logs détaillés, et visualisations 2D/3D.

Les résultats NOx sont plus aboutis du point de vue applicatif. Le meilleur checkpoint est obtenu à l'époque 163. Les métriques globales confirment un comportement réel du modèle, mais aussi les limites d'un problème fortement déséquilibré : l'accuracy moyenne est très élevée, tandis que le macro-F1 reste modéré. Les figures montrent néanmoins que plusieurs scénarios non nuls sont prédits de façon crédible, en particulier pour la localisation du panache et sa cohérence volumique générale. La contribution essentielle du projet réside donc dans cette double démonstration : d'une part, la mise en place effective d'une chaîne DeepSDF complète et scientifiquement défendable ; d'autre part, la

construction d'un système final robuste de prédiction volumique de NOx, mieux aligné avec la finalité environnementale du sujet.

Mots-clés : DeepSDF, jumeau numérique, aéroport, fonction de distance signée, OpenALAQS, Fourier Features, U-Net 3D, NOx, visualisation volumique, apprentissage profond.

1 Contexte, objectifs et logique générale du projet

1.1 Problématique générale

Le sujet de ce projet s'inscrit à l'intersection de deux enjeux. Le premier est géométrique : reconstruire une représentation 3D exploitable d'un aéroport à partir de données géospatiales hétérogènes. Le second est environnemental : utiliser cette information géométrique pour mieux comprendre et, à terme, mieux prédire les effets du bâti sur l'écoulement de l'air et la dispersion de polluants.

Dans un cadre aéroportuaire, la géométrie n'est pas un simple décor. Les bâtiments, hangars, terminaux et autres obstacles modifient la circulation locale du vent, créent des zones de recirculation et changent la manière dont un panache de pollution se diffuse. Une représentation géométrique compacte, exploitable et suffisamment fidèle constitue donc un maillon important d'une chaîne de simulation environnementale plus large.

L'énoncé initial demandait explicitement une approche fondée sur les représentations implicites, et plus précisément sur DeepSDF. L'idée directrice était d'apprendre une fonction continue capable de dire, pour toute coordonnée 3D, si le point considéré se situe à l'intérieur d'un obstacle, à l'extérieur, ou au voisinage de la surface. Ce choix est pertinent pour un jumeau numérique parce qu'il remplace une représentation volumique discrète et coûteuse par un champ neuronal compact, interrogeable à la demande.

1.2 Objectifs scientifiques et techniques

Le projet a été structuré autour de quatre objectifs principaux :

1. construire une base géométrique aéroportuaire utilisable pour l'apprentissage ;
2. entraîner un modèle DeepSDF pour approximer cette géométrie sous forme de champ implicite ;
3. évaluer la qualité de reconstruction par des métriques quantitatives et des visualisations ;
4. prolonger le travail vers une application environnementale liée à la dispersion de NOx.

Au fil du projet, l'objectif final n'a pas changé : produire un travail cohérent autour d'un environnement aéroportuaire, de sa géométrie, de son influence physique, et de l'usage de l'IA pour en modéliser les composantes clés.

1.3 Lecture du projet retenue dans ce rapport

Le présent rapport adopte la même narration scientifique que la présentation, tout en allant plus loin dans le détail. Il est organisé en deux grandes parties :

— une première partie consacrée à la chaîne *OpenALAQS + DeepSDF*, qui correspond à la tentative de jumeau géométrique au sens strict ;

— une seconde partie consacrée au pipeline volumique NOx, retenu comme axe final du projet après réception de la base HDF5.

Cette organisation permet de rendre compte du travail réel effectué : une première approche complète, intéressante et formatrice, suivie d'un pivot raisonné vers un système plus stable, plus riche en résultats, et mieux connecté à l'application finale.

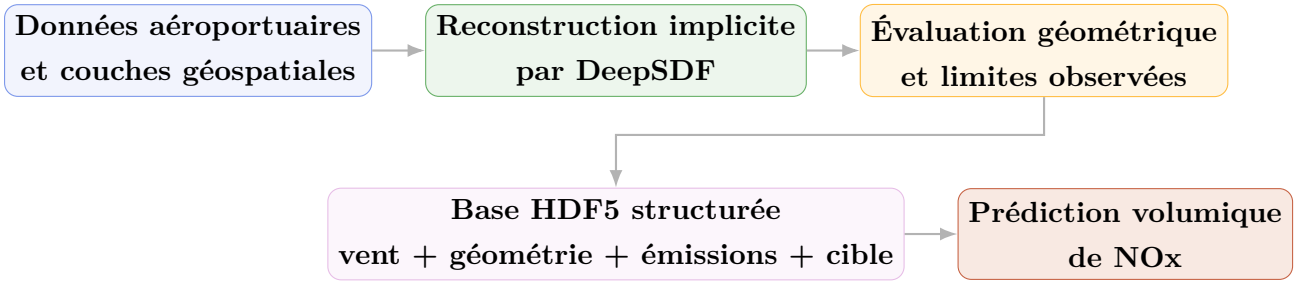


Figure 1 – Lecture d'ensemble du projet : de la reconstruction géométrique implicite à la prédiction volumique du panache de NOx.

2 Première approche : reconstruction géométrique par OpenALAQS et DeepSDF

2.1 Choix de la scène et préparation de la base aéroportuaire

La première phase du projet s'est concentrée sur la construction d'un jumeau géométrique de l'aéroport de Paris-Orly. Le travail a été mené dans un cadre inspiré d'OpenALAQS, avec QGIS comme environnement pratique de lecture des couches et QuickOSM comme outil de récupération des données OSM. L'objectif n'était pas seulement de visualiser une carte, mais de convertir des couches géographiques utiles en une base géométrique propre, interprétable par un pipeline d'apprentissage profond.

Les couches retenues au départ correspondent aux composantes physiques nécessaires à une lecture aéroportuaire cohérente : bâtiments, routes, zones de circulation, parkings, pistes et taxiways. Dans le pipeline retenu, la géométrie des bâtiments joue le rôle central, car c'est elle qui conditionne la reconstruction 3D et, plus tard, la génération du masque d'obstacles.

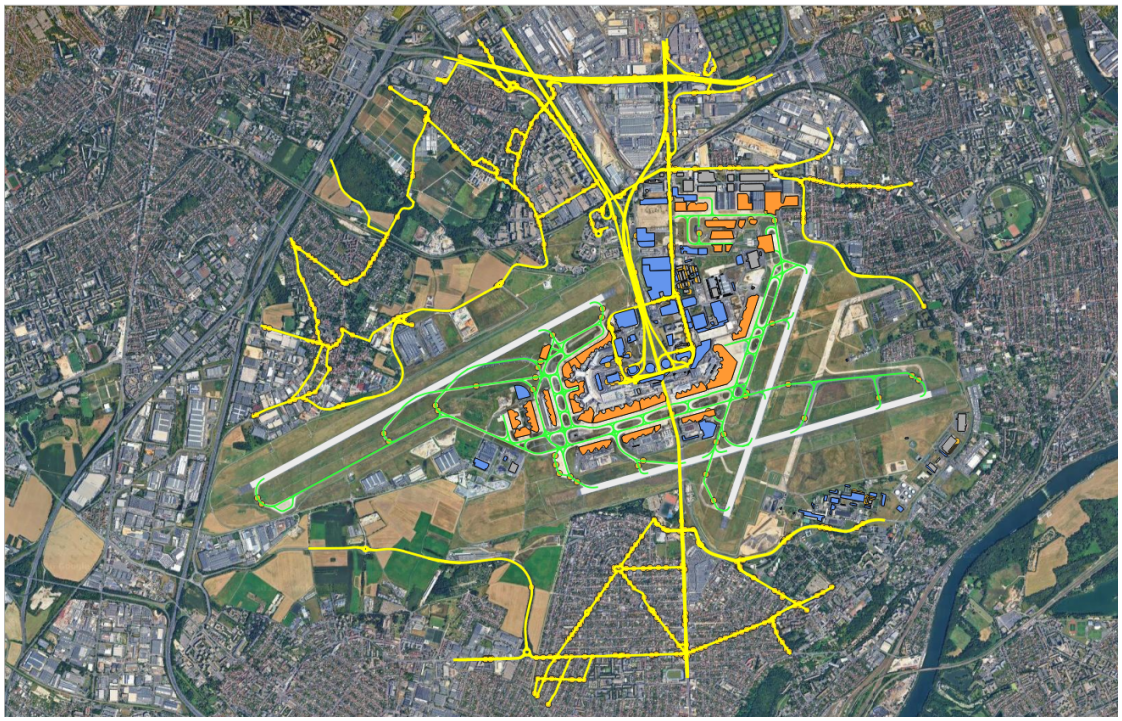


Figure 2 – Vue d'ensemble de la base aéroportuaire exploitée pour la première partie du projet. Cette étape correspond au choix de la scène, à la récupération des couches utiles et à la préparation de la géométrie de référence.

2.2 Du polygone 2D à la géométrie 3D

La difficulté immédiate est qu'OpenStreetMap fournit principalement des empreintes 2D. Pour passer à un jumeau géométrique, ces empreintes doivent être extrudées verticalement. En pratique, une extrusion 3D consiste à prendre un contour 2D fermé et à lui attribuer une hauteur afin de construire un volume. Cette étape permet d'obtenir, à partir d'une emprise de bâtiment, un solide 3D simplifié mais exploitable.

Dans le projet, la hauteur des bâtiments est lue lorsqu'elle existe, sinon estimée à partir du nombre d'étages ou d'une valeur par défaut. Une fois cette hauteur fixée, chaque polygone est transformé en volume par construction de faces latérales, du toit et de la base. Les volumes individuels sont ensuite fusionnés dans un maillage de référence unique.

Explication

La notion de **maillage de référence** doit être comprise comme un support d'apprentissage. Le réseau DeepSDF n'apprend pas directement à partir d'images, mais à partir de points 3D auxquels on associe une distance signée par rapport à cette géométrie.

2.3 Génération du dataset SDF

Une fois le maillage construit, il faut produire un dataset d'entraînement sous forme de points 3D et de valeurs de distance signée. On note classiquement la fonction SDF d'un objet Ω :

$$\mathrm{SDF}(\mathbf{x}) = \begin{cases} -d(\mathbf{x}, \partial\Omega) & \text{si } \mathbf{x} \in \Omega, \\ 0 & \text{si } \mathbf{x} \in \partial\Omega, \\ d(\mathbf{x}, \partial\Omega) & \text{sinon.} \end{cases} \tag{1}$$

Cette convention est essentielle : une valeur négative indique l'intérieur d'un obstacle, une valeur positive l'air libre, et la valeur nulle la surface reconstruite. Le dataset est ensuite construit par échantillonnage stratifié dans l'espace. L'idée n'est pas de prendre des points uniformément partout, mais de privilégier les zones les plus informatives, c'est-à-dire la surface et son voisinage immédiat.

Le run final retenu s'appuie sur les paramètres résumés dans le tableau 1. Cette configuration correspond à la version la plus stable du pipeline géométrique, après plusieurs ajustements du bruit proche surface et des bornes de clamp.

Table 1 – Paramètres principaux de génération du dataset SDF pour le run DeepSDF final.

Paramètre	**Valeur**
Aéroport retenu	Paris-Orly
Rayon de travail	1 500 m
Points de surface	200 000
Points proches de la surface	1 400 000
Points lointains	400 000
Nombre total de points	2 100 000
Écart-type du bruit proche surface	0,00075
Clamp distance	2,0
Fraction validation	3 %

Ce dataset représente un volume d'information déjà significatif pour un problème géométrique de ce type. La présence simultanée de points sur la surface, à proximité et loin des obstacles permet d'éviter deux écueils classiques : sur-apprendre une surface trop fine sans structure de volume, ou au contraire apprendre un champ trop lisse qui perd les détails géométriques.

2.4 Architecture du modèle DeepSDF

Le modèle utilisé dans cette première partie est un MLP profond chargé de prédire une distance signée à partir d'une coordonnée 3D normalisée. Le flux conceptuel est le suivant :

$$(x, y, z) \;\longrightarrow\; \gamma(x, y, z) \;\longrightarrow\; f_\theta(\gamma(x, y, z)) \;\approx\; \widehat{\mathrm{SDF}}(x, y, z), \tag{2}$$

où γ désigne l'encodage de Fourier appliqué aux coordonnées.

Le recours aux Fourier Features répond à un problème bien identifié dans la littérature des INR : un MLP standard apprend plus facilement les basses fréquences que les détails fins. L'encodage positionnel projette les coordonnées dans un espace plus riche en composantes sinusoïdales, ce qui rend l'apprentissage des arêtes, ruptures de plan et structures géométriques plus réaliste.

$$\gamma(p) = \left[\sin(2^0\pi p), \cos(2^0\pi p), \ldots, \sin(2^{L-1}\pi p), \cos(2^{L-1}\pi p)\right]. \tag{3}$$

Dans le pipeline retenu, le modèle comprend huit couches cachées de dimension 512, une connexion de saut à la couche 4, et un encodage à 8 fréquences. Le tableau 2 résume cette configuration.

Table 2 – Configuration du modèle DeepSDF et de son entraînement final.

Paramètre	**Valeur**
Type de modèle	MLP DeepSDF
Entrée	coordonnées 3D normalisées
Encodage	Fourier Features, 8 fréquences
Dimension cachée	512
Nombre de couches cachées	8
Skip connection	couche 4
Activation	ReLU
Nombre de paramètres	1 891 841
Batch size	16 384
Époques demandées	200
Optimiseur	Adam
Scheduler	Cosine learning rate
Plateforme d'entraînement	Google Colab – Tesla T4
AMP	activé, float16

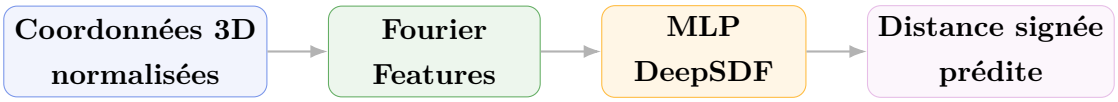


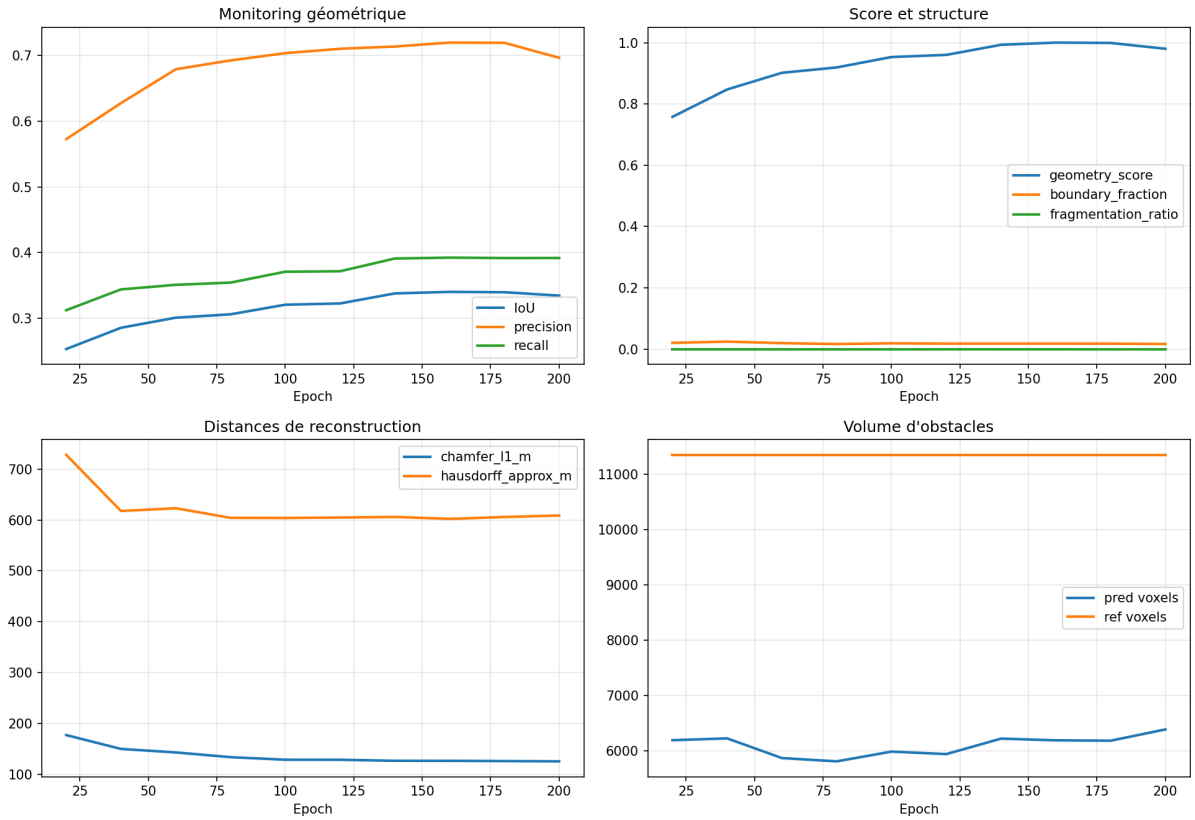
Figure 3 – Principe du modèle DeepSDF retenu pour la reconstruction géométrique.

2.5 Entraînement et suivi géométrique

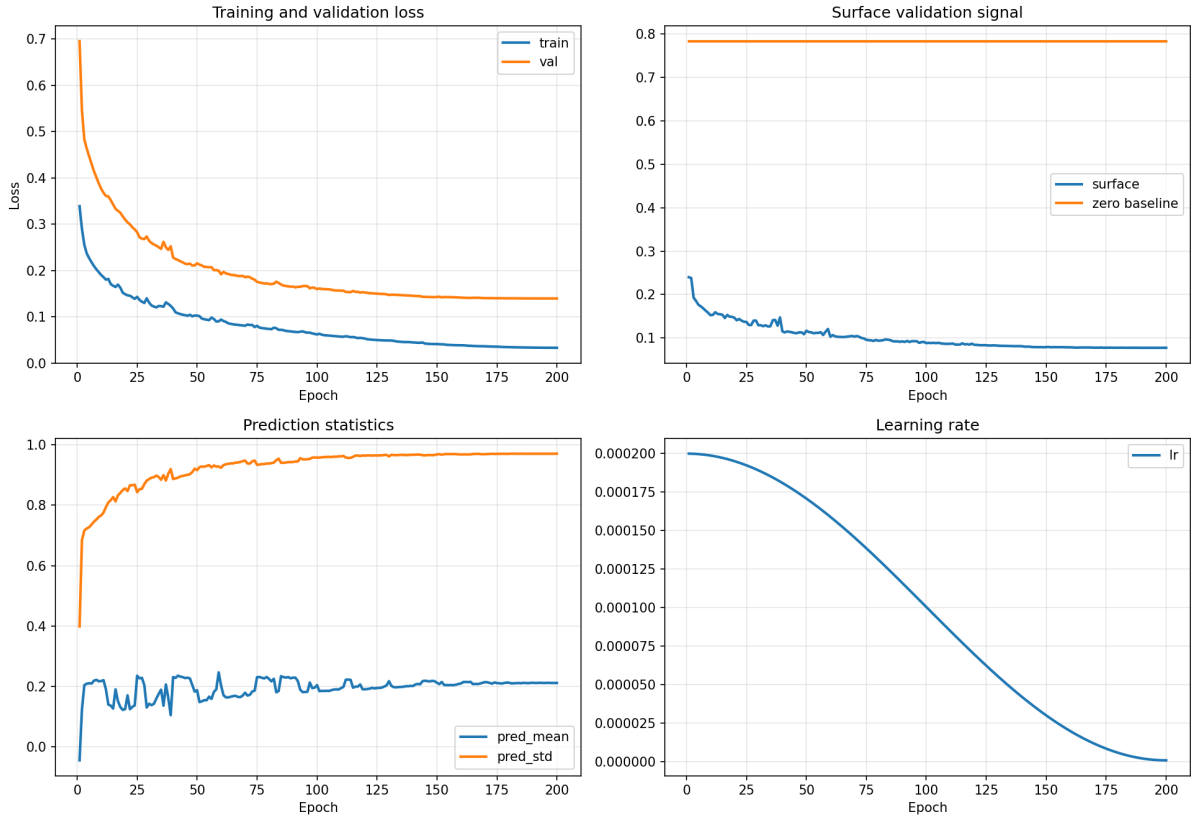
L'entraînement ici n'a pas été suivi uniquement par la loss. Comme le problème est géométrique, une bonne valeur de loss locale ne garantit pas nécessairement une reconstruction globale satisfaisante. Pour cette raison, un système de monitoring géométrique a été ajouté au code.

Tous les vingt epochs, le modèle est évalué sur une grille 3D de contrôle afin d'estimer des métriques plus directement liées à la reconstruction : IoU d'occupation, précision, rappel, fraction de composantes touchant les frontières du domaine, score géométrique agrégé, et distance de Chamfer approximative. Cette instrumentation a deux intérêts : suivre la qualité réelle de la reconstruction pendant l'entraînement, et sélectionner un meilleur checkpoint géométrique plutôt qu'un simple minimum de loss.

Au total, le modèle a été entraîné pendant 200 époques. On remarque que le meilleur modèle selon la loss de surface apparaît à l'époque 190, et que le meilleur checkpoint géométrique est distinct du meilleur checkpoint selon la validation seule.



(a) Monitoring géométrique périodique.



(b) Courbes d'entraînement et de validation.

Figure 4 – Suivi du run DeepSDF final : la loss décroît de façon cohérente et les métriques géométriques progressent globalement jusqu'à un plateau exploitable.

2.6 Reconstruction finale et rendus 3D

Après sélection du meilleur modèle géométrique, le champ SDF est évalué sur une grille dense couvrant le domaine de travail. Une surface est ensuite reconstruite à partir de l'isosurface du champ signé, puis plusieurs vues sont générées : face selon l'axe X, face selon l'axe Y, diagonale et vue de dessus.

La figure 5 montre cette reconstruction. On y distingue clairement une organisation spatiale cohérente, avec plusieurs groupes bâtis et une lecture générale plausible de la scène. Cela signifie que la chaîne DeepSDF ne s'est pas effondrée : elle a bien appris une structure géométrique utile.

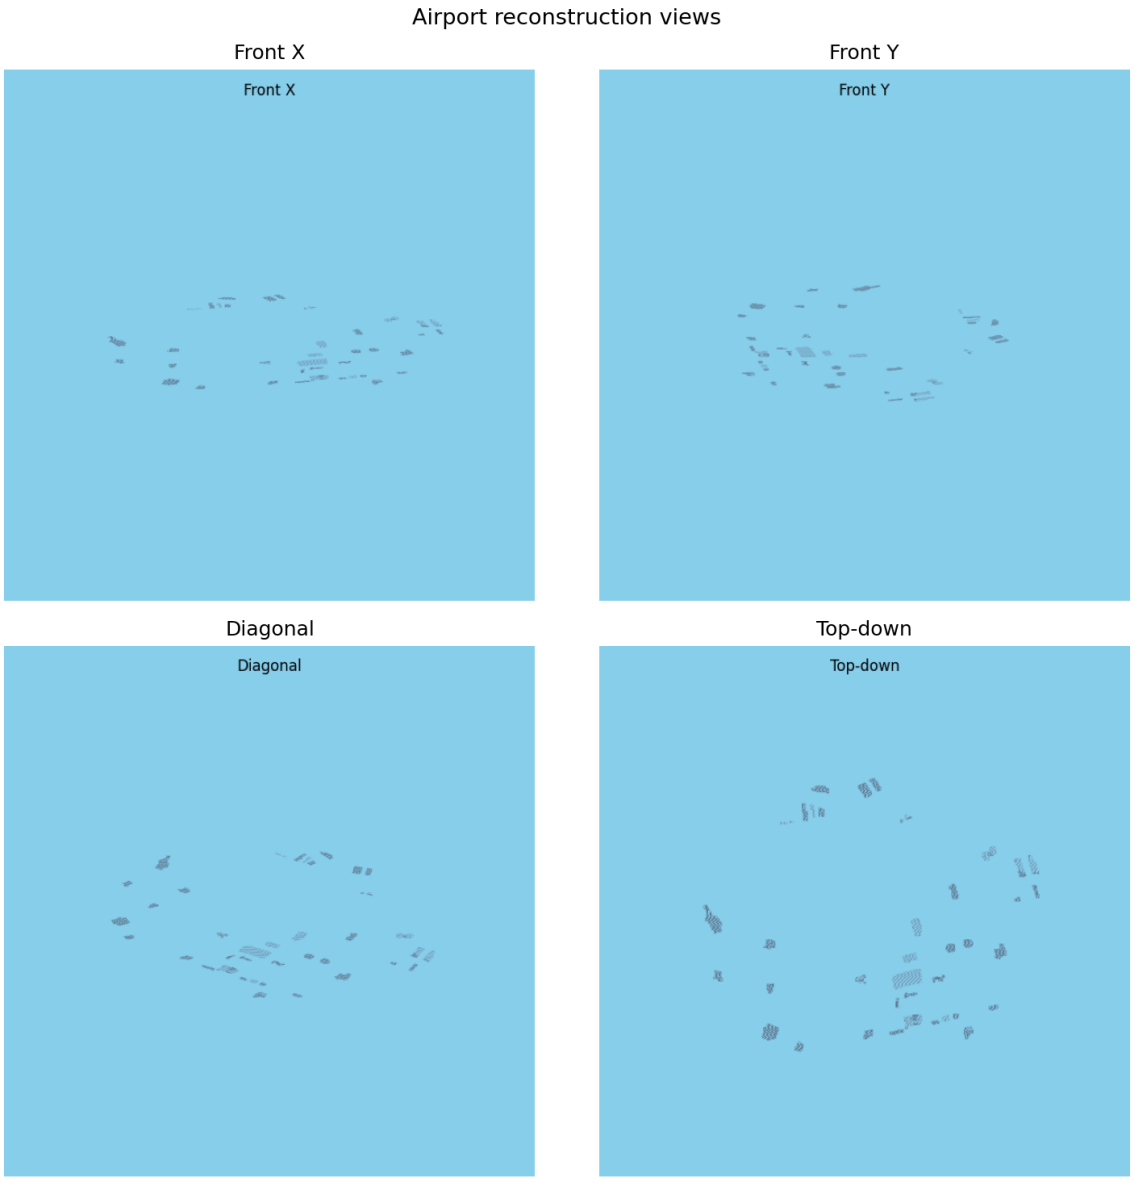


Figure 5 – Rendus principaux de la reconstruction DeepSDF finale. Les quatre vues confirment la présence d'une structure globale lisible, même si une partie significative des zones restent incomplètes.

2.7 Comparaison référence / prédiction en hauteur

L'un des points les plus utiles pour juger ce type de modèle est la comparaison de la référence et de la reconstruction à plusieurs niveaux de hauteur. La figure 6 répond précisément à cette question. À faible altitude, la structure des obstacles est bien retrouvée. À mesure que l'on monte, la prédiction reste cohérente mais perd progressivement une partie de la richesse spatiale observée dans la référence.

Ce comportement est instructif. Il montre que le modèle ne se limite pas à une simple empreinte 2D masquée ; il apprend bien une structure 3D. En revanche, la reconstruction est moins robuste dans la hauteur, ce qui pénalise le rappel global.

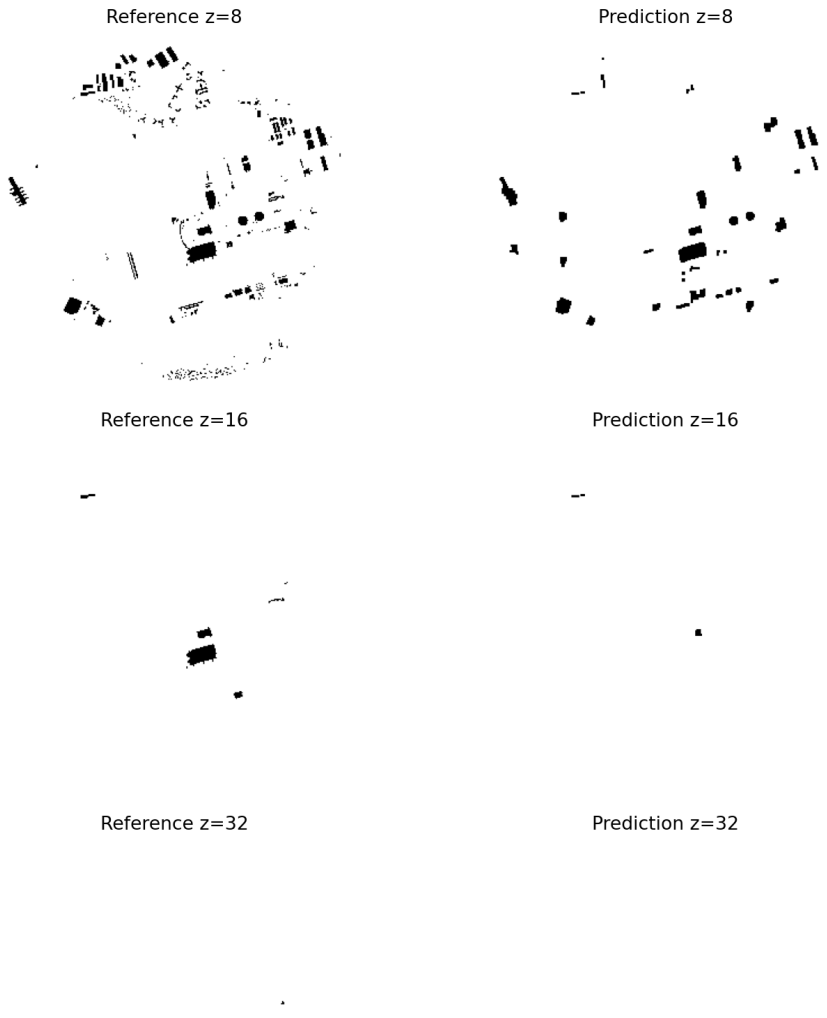
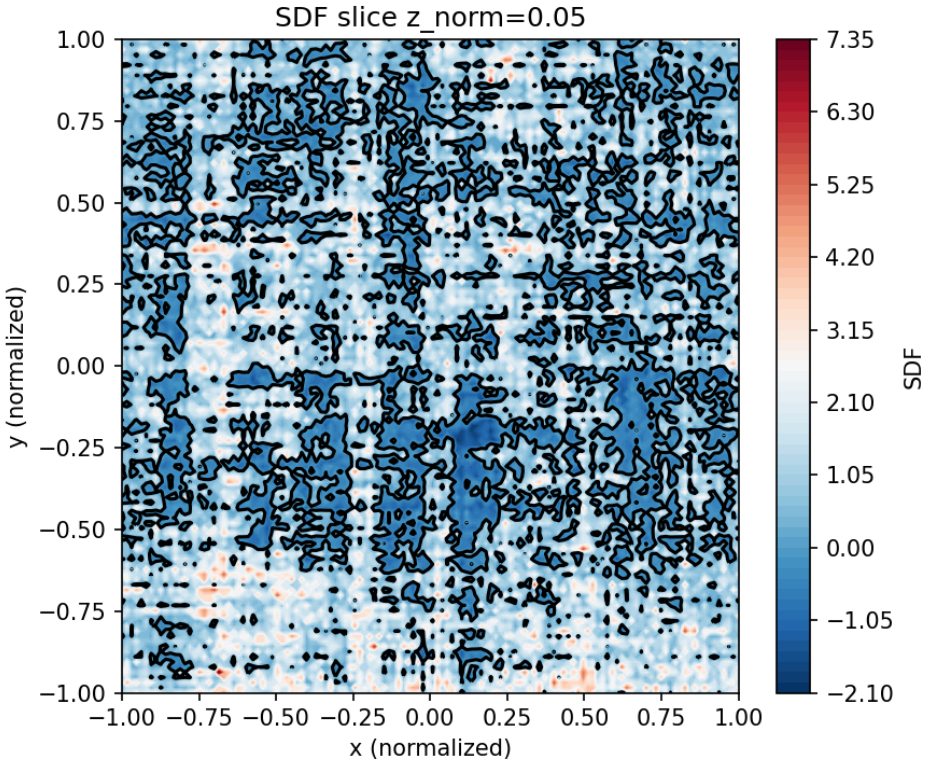


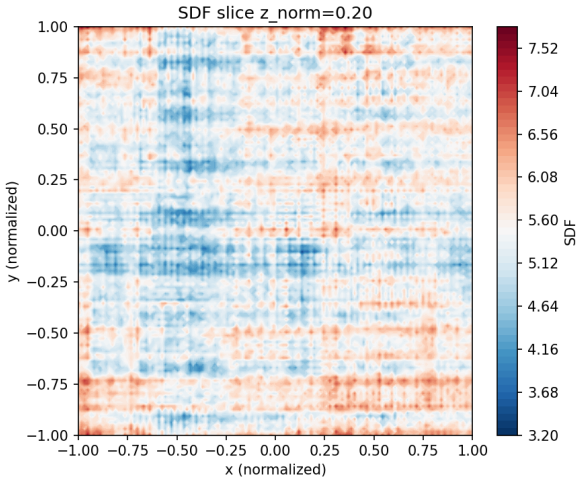
Figure 6 – Comparaison référence / reconstruction à plusieurs niveaux de hauteur.

2.8 Coupes SDF et lecture du champ appris

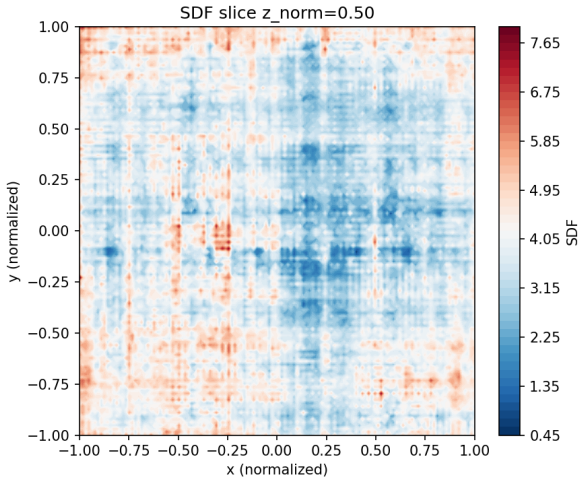
Les coupes du champ SDF apportent une lecture complémentaire. Elles ne montrent pas directement des bâtiments, mais la structure scalaire prédite par le modèle. Elles permettent de voir si les changements de signe et les gradients du champ sont cohérents avec une géométrie continue.



(a) Coupe proche du sol.



(b) Coupe intermédiaire.



(c) Coupe plus haute.

Figure 7 – Coupes du champ SDF reconstruit.

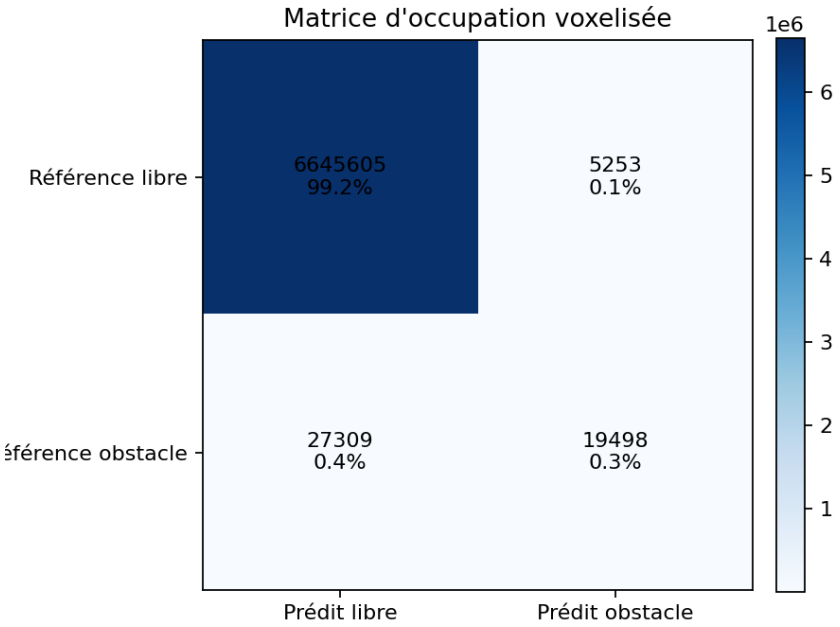
2.9 Évaluation finale et génération du masque d'obstacles

Au-delà du rendu visuel, la reconstruction a été évaluée quantitativement. Les résultats finaux sont regroupés dans le tableau 3. Ils montrent un compromis intéressant : la précision est élevée, ce qui signifie que les obstacles prédits sont généralement crédibles, mais le rappel reste modéré, signe qu'une partie des obstacles réels est encore manquée.

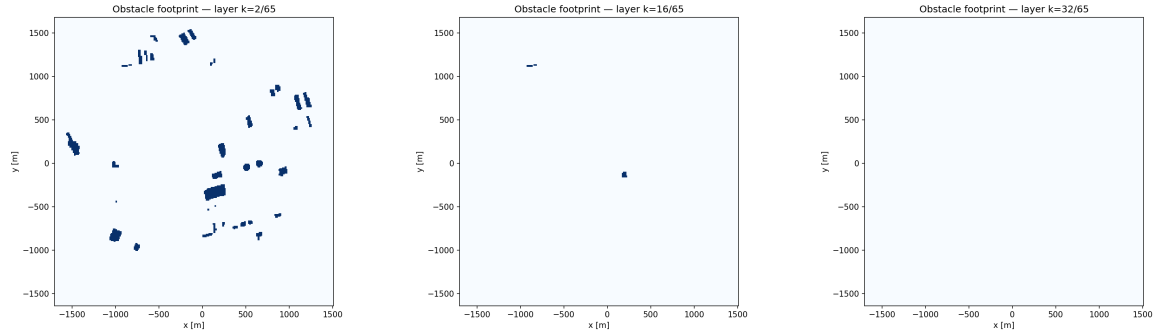
Table 3 – Métriques finales de reconstruction DeepSDF sur le run retenu.

Métrique	**Valeur**
Vertices de référence	11 252
Faces de référence	19 816
Vertices prédits	20 388
Faces prédites	40 620
Chamfer L1	123,69 m
Hausdorff approché	675,23 m
IoU d'occupation	0,3745
Précision d'occupation	0,7878
Rappel d'occupation	0,4166
Vrais positifs	19 498
Faux positifs	5 253
Faux négatifs	27 309

La figure 8 complète cette lecture en montrant, d'une part, la matrice d'occupation binaire obstacle/libre, et d'autre part, trois coupes du masque généré. On voit bien que le système produit un masque non vide et spatialement cohérent.



(a) Évaluation binaire obstacle / air.



(b) Coupes du masque d'obstacles généré.

Figure 8 – Le pipeline géométrique aboutit bien à un masque 3D exploitable, mais ce masque reste trop incomplet pour constituer à lui seul une représentation satisfaisante.

Résultat important

Le run final DeepSDF montre que la chaîne entière fonctionne : base aéroportuaire, extrusion 3D, dataset SDF, apprentissage implicite, reconstruction et génération d'un masque d'obstacles. Cette première approche est donc scientifiquement défendable, même si elle ne suffit pas comme résultat principal.

2.10 Pourquoi cette première approche n'a pas été retenue comme résultat principal

Le point clé n'est pas que la reconstruction serait "fausse" ou inutilisable ; le point clé est qu'elle reste encore trop incomplète par rapport à l'ambition du sujet. Plusieurs optimisations ont été apportées au code pour améliorer la stabilité : meilleure répartition

des points SDF, suivi géométrique pendant l'entraînement, sélection sur meilleur checkpoint géométrique, nettoyage de la reconstruction finale et contrôle des composantes parasites. Ces améliorations ont produit un résultat nettement meilleur que les premières tentatives.

Cependant, le niveau atteint ne justifie pas de consacrer l'ensemble du rendu final à cette seule partie. Le rappel insuffisant, les distances géométriques encore élevées et la perte de structure à certains niveaux de hauteur indiquent qu'une poursuite des relances n'aurait probablement apporté que des gains marginaux au regard du temps disponible. C'est ce constat qui motive la transition vers la seconde partie du projet.

⚠ Point critique

Le recentrage vers NOx répond à un arbitrage méthodologique fondé sur la robustesse des résultats obtenus, mais une décision de recherche raisonnée : conserver une première partie DeepSDF solide, puis orienter le résultat final vers un système mieux instrumenté et plus convaincant sur le plan applicatif.

3 Seconde approche : prédiction volumique de dispersion de NOx

3.1 Introduction

La seconde partie du projet s'inscrit dans la continuité de la première, mais elle déplace le centre du problème. Dans la partie DeepSDF, l'objectif principal était de reconstruire une géométrie 3D continue à partir d'une scène aéroportuaire. Ici, l'enjeu devient plus directement physique et applicatif : il ne s'agit plus de prédire une surface, mais un **champ volumique de concentration de NOx** dans tout l'espace étudié.

Le problème est donc reformulé comme une tâche de prédiction supervisée sur volumes 3D. Pour un scénario atmosphérique donné, on dispose de plusieurs champs décrivant le contexte : les composantes du vent, la géométrie du site sous forme de champs signés, ainsi que les émissions. À partir de ces informations, le modèle doit produire un volume 3D de concentration. La sortie n'est plus une géométrie implicite, mais une distribution spatiale du polluant, c'est-à-dire une estimation de la manière dont le panache se forme, se déplace et se diffuse dans la scène.

3.2 Caractéristiques de la base HDF5

La base fournie par l'enseignant contient 3 000 scénarios 3D. Chaque scénario est un cas complet de simulation comprenant plusieurs champs volumiques ainsi que des métadonnées décrivant le contexte. Le jeu de données dans le run final occupe environ 116 Go et couvre quatre catégories d'aéroport, six classes de stabilité atmosphérique, ainsi que trois tailles principales de grille.

Table 4 – Caractéristiques globales de la base HDF5 utilisée pour la prédiction de NOx.

Propriété	**Valeur**
Nombre total de scénarios	3 000
Catégories	4 catégories de 750 scénarios
Classes de stabilité	6 classes de 500 scénarios
Tailles de grille	140^2, 300^2 et 500^2 en plan, avec 64 couches verticales
Scénarios *zero-case proxy*	422 (14,07 %)
Taille du fichier HDF5	116 Go
Support d'exécution	serveur GPU avec NVIDIA H100 PCIe

Dans cette base, un **scénario** doit être compris comme un cas complet de dispersion. Il associe une géométrie donnée, des conditions météorologiques données, un niveau d'activité de particules donné, et une concentration cible de NOx sur tout le volume. Cette structuration est importante : le modèle n'apprend pas un instantané isolé, mais une relation entre contexte physique et panache résultant.

3.3 La notion de scénario

Quelques exemples issus des métadonnées montrent la variété des cas présents dans la base. Un scénario peut être de taille modeste ($140 \times 140 \times 64$), moyen ($300 \times 300 \times 64$) ou plus exigeant ($500 \times 500 \times 64$). Il est aussi caractérisé par :

- une catégorie d'aéroport ;
- une classe de stabilité atmosphérique ;
- une vitesse de vent mesurée à 10 mètres, notée U_{10} ;
- un nombre de particules actives ;
- un indicateur *zero-case proxy* signalant les cas sans panache actif.

Tous les scénarios n'ont pas la même difficulté, et la base contient des cas très simples, des cas vides, mais aussi des panaches plus denses et plus complexes.

3.4 Entrées, sortie et représentation volumique

Le modèle NOx travaille sur des tenseurs 3D multi-canaux. Chaque scénario est converti en un empilement de volumes d'entrée décrivant simultanément l'aérodynamique, la géométrie et l'activité émissive de la scène. Dans le run final, sept canaux d'entrée sont utilisés.

Table 5 – Canaux d'entrée du modèle NOx et rôle physique associé.

Canal	**Rôle**
wind_u	composante horizontale du vent selon l'axe X
wind_v	composante horizontale du vent selon l'axe Y
wind_w	composante verticale du vent
obstacle_sdf	description géométrique des obstacles bâtis sous forme de distance signée
gse_sdf	information liée aux équipements et structures au sol
lto_sdf	information liée aux zones d'activité aéroportuaire
emissions_total	champ total d'émissions servant de source au panache

La cible du modèle est un volume 3D unique : la grille de concentration de NOx. Formellement, on peut résumer le problème par :

$$X \in \mathbb{R}^{7\times N_z\times N_y\times N_x} \quad \longrightarrow \quad \widehat{Y} \in \mathbb{R}^{1\times N_z\times N_y\times N_x}, \tag{4}$$

où X regroupe les sept champs d'entrée et $\widehat{Y}$ représente la concentration prédite.

3.5 Architecture du modèle final

Le modèle retenu est un **3D U-Net**. Cette architecture est adaptée aux données volumiques car elle combine une phase d'encodage, qui résume progressivement la scène, et une phase de décodage, qui reconstruit une sortie dense en s'appuyant sur des connexions de saut. Le rôle de ces connexions est de conserver des détails spatiaux utiles pendant la reconstruction de la sortie.

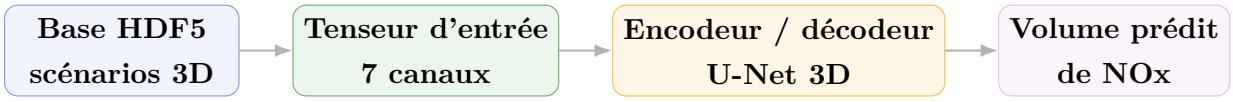


Figure 9 – Lecture fonctionnelle du pipeline NOx.

Le modèle final comporte 22,583 millions de paramètres entraînables, avec une base de canaux à 32. Ce choix est plus lourd que la partie DeepSDF, mais reste cohérent avec la nature 3D dense du problème.

3.6 Protocole d'entraînement et cadre expérimental

L'entraînement final a été réalisé sur un serveur de calcul équipé d'un GPU NVIDIA H100 PCIe, qui est la carte graphique retenue après des essais sur d'autres configurations moins adaptées à la nature du problème, à la quantité de données et à la taille du modèle.

Table 6 – Cadre expérimental du run NOx final.

Paramètre	**Valeur**
Modèle	3D U-Net
Canaux d'entrée	7
Base de canaux	32
Paramètres entraînables	22,583 millions
Dataset HDF5	116 Go
Plateforme	serveur GPU
GPU	NVIDIA H100 PCIe (84,9 Go mémoire)
Train brut	2 400 scénarios
Train effectif	2 072 scénarios
Validation	300 scénarios
Test	300 scénarios
Époques totales	200
Meilleur checkpoint	époque 163
Métrique de sélection	*selection_plume_rmse*

Le split retenu est stratifié par catégorie et stabilité. Les scénarios *zero-case proxy* sont retirés du train pour éviter un apprentissage trop fortement attiré par le fond. Ils restent en revanche présents dans les ensembles de validation et de test, ce qui permet d'évaluer honnêtement le comportement du modèle sur des cas vides.

3.7 Stabilisation du notebook final

Le notebook final n'a pas été stable dès la première version. Plusieurs difficultés ont été rencontrées : crash de précision mixte, validation peu représentative, effondrement du modèle vers la classe de fond, puis problèmes de visualisation 3D après entraînement.

Table 7 – Principales corrections apportées au pipeline NOx.

Problème identifié	**Correction apportée**
- Crash lié au *bfloat16* sur le serveur	- adaptation du chemin d'inférence et de conversion pour éviter les incompatibilités NumPy / PyTorch.
- Modèle trop attiré par la classe de fond	- pondération plus forte des zones de panache et sélection sur une métrique dédiée au panache.
- Validation faible	- ajout d'un sous-ensemble de sélection volumique.
- Visualisations finales fragiles	- correction des cellules 3D et vidéo, puis régénération des sorties sur un scénario représentatif.

4 Résultats expérimentaux du système NOx

4.1 Courbes d'apprentissage

La figure 10 présente les courbes d'entraînement du système NOx. On y lit plusieurs informations importantes. D'abord, la loss totale décroît de manière stable, ce qui confirme que l'optimisation ne diverge pas. Ensuite, les composantes plus spécialisées, notamment celles liées au panache, suivent une évolution cohérente. Enfin, la différence entre l'accuracy et le macro-F1 montre immédiatement le déséquilibre de classes : le fond domine très largement le volume, si bien qu'une très forte accuracy ne suffit pas à conclure à un bon comportement global.

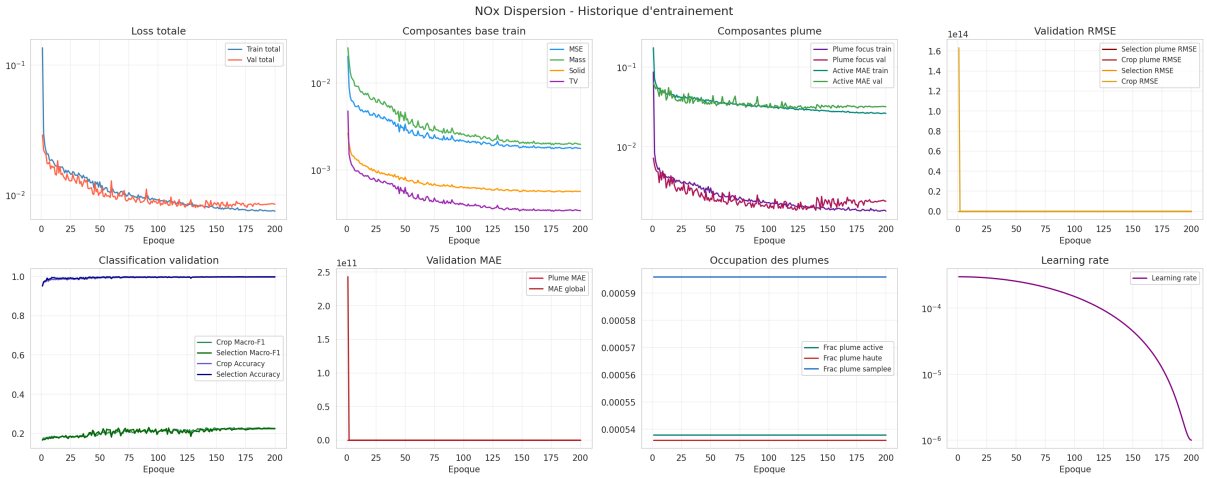


Figure 10 – Courbes d'apprentissage du run NOx final. Le meilleur checkpoint est retenu à l'époque 163 sur une métrique de panache.

4.2 Lecture des métriques globales

Le tableau 8 résume les métriques les plus utiles : l'accuracy et le weighted F1 sont très élevés parce que la majorité des voxels appartiennent à la classe de fond. Le macro-F1, en revanche, est bien plus révélateur de la difficulté réelle du problème.

Table 8 – Métriques globales du run NOx final.

Indicateur	**Valeur**
Accuracy moyenne par scénario	0,9984
Weighted F1 moyen	0,9990
Macro F1 moyen	0,2127
Accuracy voxel globale	0,9982
Macro F1 voxel global	0,2105
Weighted F1 voxel global	0,9988
Meilleur R^2 observé sur un scénario	0,5280
Meilleur scénario de démonstration	scenario_05877
Meilleur checkpoint	époque 163

Un bon moyen d'interpréter ces valeurs est de distinguer les cas non nuls et les *zero-cases*. Le tableau 9 montre que les scénarios non nuls sont mieux représentatifs de la difficulté réelle : le macro-F1 y reste supérieur, alors que les *zero-cases* gonflent artificiellement l'accuracy.

Table 9 – Lecture comparative entre scénarios non nuls et *zero-case proxy*.

Indicateur	**Scénarios non nuls**	**Zero-case proxy**
Nombre de scénarios	255	45
Accuracy moyenne	0,9982	0,9997
Macro F1 moyen	0,2208	0,1666
Plume voxel fraction moyenne	0,000365	0,000000

Explication

Ces chiffres montrent pourquoi l'accuracy seule serait trompeuse dans ce projet. Un modèle peut très bien prédire le fond presque partout et obtenir un excellent score global, tout en restant médiocre sur les zones réellement importantes du panache.

4.3 Matrice de confusion

La matrice de confusion de la figure 11 donne une lecture plus fine par classe de concentration. La classe 0–10 domine massivement le volume et explique les scores globaux élevés. Les classes intermédiaires sont plus difficiles : elles sont moins fréquentes, plus diffuses spatialement et souvent moins stables d'un scénario à l'autre. À l'inverse, la classe la plus élevée (>500) est mieux retrouvée, car elle correspond souvent à un signal plus concentré et mieux localisé.

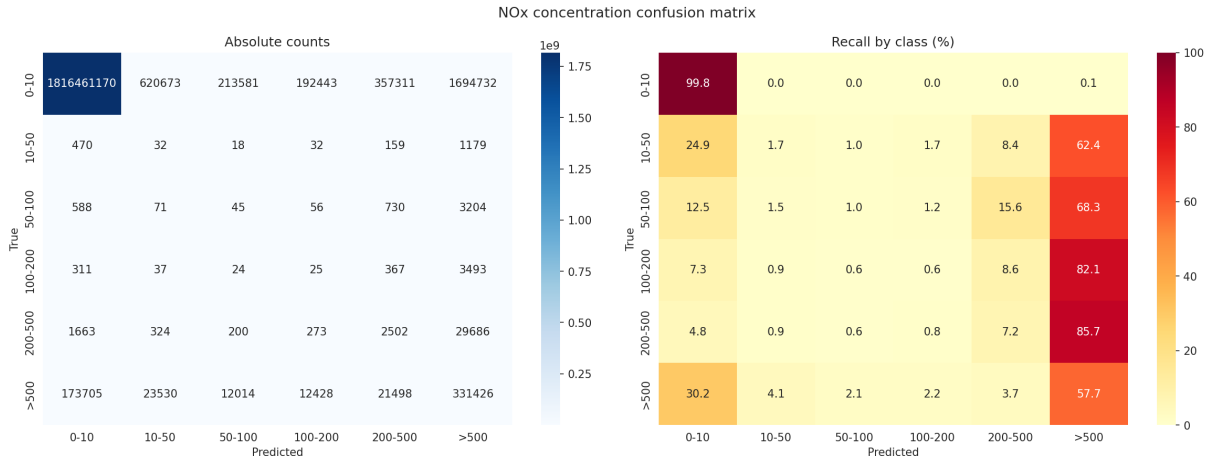


Figure 11 – Matrice de confusion du modèle NOx.

4.4 Analyse qualitative sur des scénarios représentatifs

Les coupes volumétriques permettent de voir ce que le modèle apprend réellement. La figure 12 présente un scénario non nul de difficulté modérée. La vérité terrain montre un panache actif près du sol ; la prédiction récupère une partie de la structure utile, même si elle reste plus diffuse que la référence.

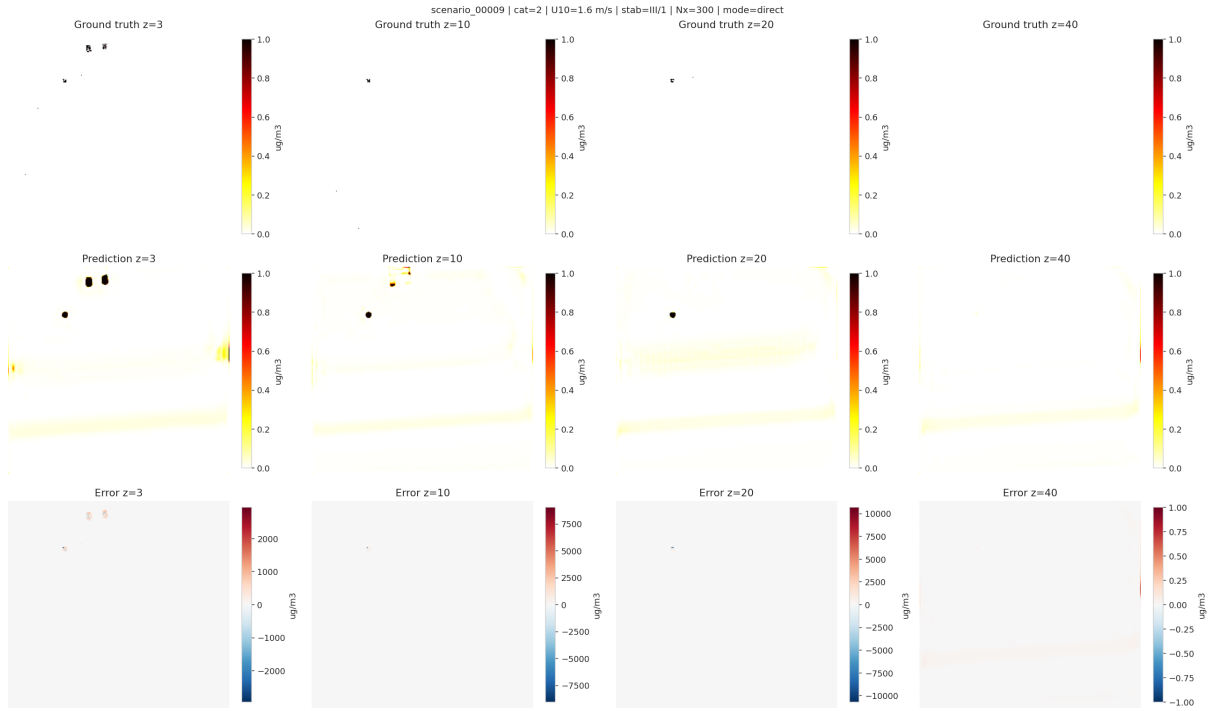


Figure 12 – Scénario 00009. Le modèle retrouve plusieurs zones actives du panache, mais avec un fond plus diffus que la vérité terrain.

La figure 13 illustre un scénario plus difficile. La grille est plus grande, la scène plus complexe et le nombre d'obstacles plus élevé. Le modèle conserve une cohérence globale du signal, mais il lisse davantage la structure du panache et perd une partie de la finesse observée dans la vérité terrain.

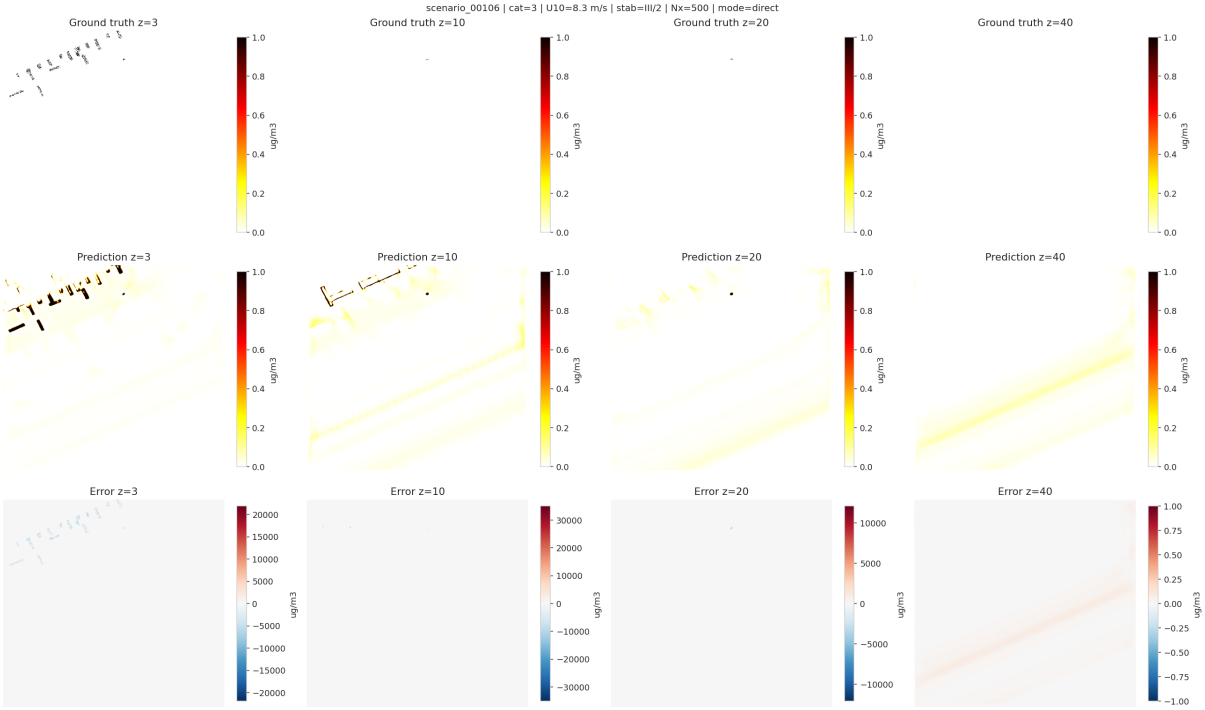


Figure 13 – Scénario `00106`. La scène plus complexe met en évidence la limite principale du modèle : une tendance au lissage qui réduit la précision spatiale du panache.

4.5 Meilleurs et pires cas

La figure 14 est particulièrement utile pour une lecture globale du modèle. Les meilleurs cas montrent que le système peut réellement localiser un panache de manière plausible. Les pires cas rappellent cependant que la généralisation n'est pas homogène sur tout l'espace des scénarios. Cette hétérogénéité n'est pas anormale dans un problème volumique aussi déséquilibré et varié.



Figure 14 – Comparaison entre meilleurs et pires scénarios du modèle NOx.

4.6 Lecture des scénarios les plus favorables

Le tri des scénarios de test confirme que plusieurs cas non nuls sont prédits de façon encourageante. Les meilleurs scénarios observés selon le coefficient R^2 sont listés dans le tableau 10. Cette liste montre que les meilleurs résultats apparaissent sur des scénarios physiquement non triviaux, avec vent non nul et particules actives.

Table 10 – Meilleurs scénarios de test selon R^2 sur le run final NOx.

Scénario	R^2	**Plume** R^2	**Cat.**	U_{10}	**Commentaire**
scenario_05877	0,5280	0,4637	2	1,41	scénario retenu pour les visualisations 3D
scenario_09553	0,5117	0,3847	2	5,05	cas stable et lisible
scenario_09253	0,4811	0,4108	2	7,77	bon compromis entre intensité et structure
scenario_05801	0,4601	-0,0895	2	13,33	bonne reconstruction, panache plus difficile
scenario_06161	0,4252	0,0514	2	1,74	localisation correcte, structure plus diffuse

4.7 Visualisations 3D et vidéo

Le pipeline final produit également deux artefacts multimédias : une visualisation 3D interactive du scénario `05877` et une vidéo parcourant le volume selon l'axe vertical.

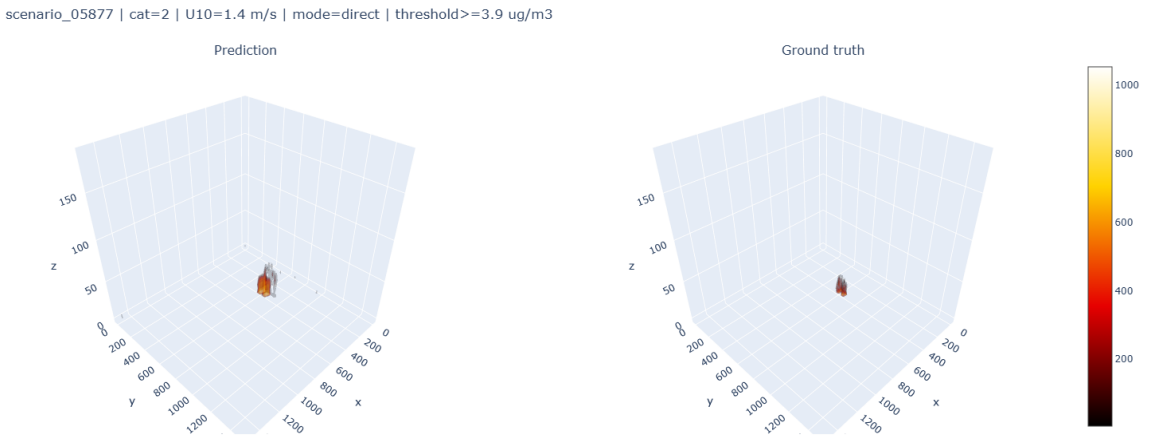


Figure 15 – Visualisation 3D du scénario 05877

4.8 Bilan scientifique

Le run final NOx n'est pas parfait, mais il est solide. Il montre un apprentissage réel, une instrumentation sérieuse et un niveau de résultats suffisamment cohérent. La difficulté reste concentrée sur trois points : les cas quasi vides, le déséquilibre des classes et la finesse spatiale des panaches complexes. En revanche, la structure générale, la localisation et la dynamique verticale du signal sont apprises de façon crédible sur plusieurs scénarios.

5 Discussion générale, limites et perspectives d'adaptation

5.1 Ce que le projet démontre

Le projet démontre d'abord qu'une chaîne complète de jumeau géométrique par DeepSDF peut être mise en place dans un cadre aéroportuaire réel : ingestion de données, construction d'une géométrie de référence, génération d'un dataset SDF, entraînement d'un champ implicite, reconstruction et génération d'un masque.

Il démontre ensuite qu'une base volumique structurée peut servir de support à une seconde étape plus applicative, orientée vers la prédiction d'un panache de pollution. Ce second volet est particulièrement intéressant du point de vue de l'IA appliquée, car il transforme la compréhension géométrique du site en un problème de prédiction volumique, où la géométrie, la météorologie et les émissions interagissent.

5.2 Limites identifiées

Les limites du projet sont de deux natures.

Limites de la partie DeepSDF. La reconstruction géométrique finale reste partielle. Malgré des progrès nets, le modèle oublie encore une partie importante des obstacles. Les métriques géométriques restent éloignées de ce que l'on attendrait d'un jumeau numérique fidèle.

Limites de la partie NOx. Le modèle volumique apprend surtout bien la classe dominante de fond, ce qui rend les métriques agrégées difficiles à lire. Les classes intermédiaires de concentration sont mal séparées, et les *zero-cases* restent une zone délicate. En outre, les scénarios les plus complexes montrent une tendance au lissage du panache.

5.3 Perspectives d'amélioration côté DeepSDF

Pour prolonger la partie géométrique, on distingue plusieurs pistes :

1. enrichir la scène avec des données de hauteur plus précises, par exemple issues d'une source plus détaillée que l'OSM brut ;
2. travailler sur une stratégie multi-résolution, afin de concentrer le modèle sur les zones bâties denses plutôt que sur un domaine trop large ;
3. explorer une régularisation supplémentaire du champ implicite, par exemple via une supervision hybride ;
4. renforcer la validation géométrique intermédiaire avec davantage d'échantillons de contrôle.

5.4 Perspectives d'amélioration côté NOx

Pour la partie NOx, les pistes les plus claires sont les suivantes :

1. réintroduire progressivement une partie des *zero-cases* dans l'entraînement pour améliorer le réalisme du fond sans provoquer de collapse ;
2. mieux équilibrer les classes de concentration, soit par pondération, soit par stratégie d'échantillonnage ;
3. ajouter une tête auxiliaire de détection de scénario actif / quasi nul ;
4. améliorer la qualité des visualisations 3D en conservant un mode interactif et une vidéo de meilleure lecture volumique ;
5. tester la transférabilité du pipeline à d'autres aéroports ou à d'autres polluants.

6 Conclusion

Ce projet a suivi une trajectoire scientifique claire, même si cette trajectoire n'a pas été linéaire. La première étape a consisté à mettre en place une véritable chaîne de reconstruction géométrique implicite à partir d'une base aéroportuaire. Cette partie a donné des résultats réels : un dataset SDF de grande taille, un entraînement stable, des reconstructions visuelles crédibles et un masque d'obstacles quantitativement évalué. Elle a surtout permis de valider la compréhension technique du sujet initial.

La seconde étape a consisté à reconnaître que, malgré ces progrès, la reconstruction géométrique restait encore trop incomplète pour constituer le résultat principal du projet. L'utilisation de la base HDF5 était une manière cohérente pour poursuivre le projet sur un versant plus applicatif : la prédiction volumique de la dispersion de NOx dans un contexte aéroportuaire.

Le notebook NOx final, son run complet de 200 époques, ses métriques, ses courbes d'apprentissage et ses visualisations démontrent un système nettement plus mature pour la partie aval de la chaîne. Les résultats restent perfectibles, en particulier sur les classes intermédiaires et les scénarios vides, mais ils sont suffisamment solides pour soutenir une analyse détaillée et une soutenance devant un jury.

En synthèse, le projet aboutit à une conclusion : la reconstruction géométrique implicite constitue une base conceptuelle pertinente pour un jumeau numérique d'aéroport, mais sa mise en œuvre robuste à l'échelle d'une scène réelle demeure exigeante. En parallèle, un pipeline de prédiction volumique comme celui développé pour NOx montre qu'un travail appliqué, rigoureux et bien instrumenté peut produire des résultats défendables et scientifiquement intéressants à partir d'une base structurée. Le cœur du rapport est précisément là : avoir mené les deux approches jusqu'à un niveau suffisant pour comprendre leurs apports, leurs limites, et les perspectives qu'elles ouvrent.